# Ghép ảnh 2D từ video UAV biết rủi ro và thích ứng tài nguyên: một nghiên cứu thực nghiệm

Diệp Quang Sáng, Nguyễn Đức Nam, Đào Đặng Nguyên Khôi, Trương Quang Đăng Khoa
AI2002, Nhóm 09
Trường Đại học FPT, Thành phố Hồ Chí Minh

*Abstract*: Ghép ảnh tuần tự từ video UAV hỏng một cách âm thầm: một phép đăng ký sai bị tích luỹ vào bản đồ và mọi frame sau đều thừa hưởng sai số đó. Bộ đối sánh cổ điển rẻ nhưng dễ vỡ trên địa hình nghèo đặc trưng; bộ đối sánh học sâu bền nhưng quá chậm để chạy cho mọi frame. Chúng tôi nghiên cứu ba cơ chế trên một pipeline homography tích luỹ: bộ chỉ báo rủi ro rẻ ở cấp bước, bộ phân luồng đối sánh hai tầng, và ba chiến lược phục hồi, tất cả đều đo so với matcher tham chiếu SIFT ảnh gốc trên hai cửa sổ 45 bước của bộ dữ liệu NPU Drone-Map. Ba phát hiện chính: (i) chỉ báo đếm điểm *không* tách được bước sai (AUC 0,40 cho `matches`, 0,41 cho `inliers`, tức thấp hơn mức đoán mò), trong khi bằng chứng sau khi ghép thì tách được (AUC 0,77–0,86); (ii) chạy matcher học sâu cho *mọi* bước vừa chậm vừa tệ hơn chỉ dùng SIFT (60,4 s / 82,4 px so với 3,2 s / 75,3 px drift cuối), còn phân luồng ở $\tau_{\text{ncc}}$=0,93 leo thang 16% số bước và đạt 28,5 px, nghĩa là điểm làm việc tốt nằm trong một khoảng hẹp, không đơn điệu theo ngưỡng; (iii) dưới cùng một ngưỡng kích hoạt, chiến lược tách mảnh giữ đủ 46/46 frame, còn bỏ frame và rematch keyframe chỉ giữ 14/46 do trigger dây chuyền. Kết luận bị giới hạn ở hai cửa sổ được chọn sẵn, một bộ dữ liệu, và thước đo sai số là đồng thuận với matcher tham chiếu.

*Index Terms*: Ghép ảnh UAV, dự báo lỗi đăng ký, phân luồng bộ đối sánh, ước lượng homography, trôi dạt tích luỹ, chiến lược phục hồi.

## I. Giới thiệu

Ghép một chuyến bay UAV thành một ảnh 2D duy nhất là phương án rẻ hơn nhiều so với tái tạo quang trắc đầy đủ, khi mục tiêu chỉ là một bức ảnh hiện trạng cục bộ. Công thức chuẩn là tích luỹ: ghép frame $i$ với frame $i-1$, ước lượng homography $H_i$, tích luỹ lại và hoà trộn các frame đã warp. Kiểu hỏng cũng chuẩn không kém: trên địa hình nghèo vân hoặc lặp vân, ước lượng từng cặp suy biến, và vì mỗi bước đều điều kiện hoá theo bước trước, một $H_i$ sai sẽ kéo lệch toàn bộ các frame phía sau (tích luỹ drift).

Văn liệu đưa ra hai thái cực. Pipeline thủ công (SIFT/ORB với RANSAC [1], [2], [3]) đủ nhanh để chạy CPU tại hiện trường nhưng vỡ ở frame khó; matcher học sâu (SuperPoint+LightGlue [4], [5], họ LoFTR [6], [7]) xử lý được các frame đó nhưng tốn hơn một đến hai bậc độ lớn, điều này quan trọng khi cả chuyến bay phải xử lý trên laptop hay trong một phiên Colab. Các hệ thống tích luỹ hiện có phần lớn nhận hoặc loại frame bằng một ngưỡng kinh nghiệm cố định [9], [10] chứ không quyết định *frame này đáng bao nhiêu tính toán*, và các hành vi phục hồi xuất hiện rải rác trong từng công trình (bỏ frame, rematch keyframe cũ, đóng mảnh con) chưa từng được so sánh dưới cùng một ngưỡng kích hoạt trên cùng một pipeline.

Bài này báo cáo một nghiên cứu thực nghiệm trả lời bốn câu hỏi trên một pipeline tích luỹ:

- **RQ1 (dự báo lỗi).** Chỉ báo rẻ nào ở cấp bước thật sự tách được bước ghép sai khỏi bước ghép tốt?
- **RQ2 (phân luồng).** Chính sách hai tầng (mặc định dùng matcher cổ điển, chỉ gọi matcher học sâu ở bước bị gắn cờ) mua được gì về chi phí và về chất lượng bản đồ, so với luôn-cổ-điển và luôn-học-sâu?
- **RQ3 (phục hồi).** Dưới cùng một ngưỡng, bỏ frame, rematch frame đã đặt và tách mảnh con khác nhau thế nào về số frame giữ được và về drift?

Đóng góp của chúng tôi chính là các số đo, trong đó có hai kết quả phủ định mà chúng tôi cho là phần dễ chuyển giao nhất: số inlier phản tác dụng ở cấp bước, và gọi matcher mạnh cho mọi bước làm bản đồ *tệ hơn* matcher rẻ trên cửa sổ đã đo.

## II. Công trình liên quan

**Ghép ảnh UAV tích luỹ và khuyết thiếu kiểm soát rủi ro.** Các pipeline ghép ảnh bay chụp tuần tự nhìn chung đi theo hai nhánh: visual odometry trực tiếp kết hợp bundle adjustment cục bộ (tiêu biểu như Map2DFusion [22]), đòi hỏi tài nguyên tính toán lớn và giả định chuyển động liên tục; hoặc xâu chuỗi homography từng cặp dựa trên đặc trưng [9], [10], [12], [11] để ưu tiên tốc độ. Trong nhóm dựa trên đặc trưng, các pipeline tuần tự hướng CPU dùng ORB/SIFT kết hợp RANSAC thường giới hạn số điểm hoặc áp dụng ngưỡng số inlier cố định để loại bỏ frame kém [9]; Li et al. [10] tối ưu sai số chiếu lại có trọng số và rematch keyframe cũ để hãm drift; Chen et al. [12] dùng quy hoạch động tìm seamline tối ưu và phép biến đổi half-projective warp xử lý mặt đất gồ ghề; còn Kharismawati và Kazic [11] dùng dòng quang học Farneback kết hợp phân cụm submosaic cho nông nghiệp. Điểm hạn chế cốt tử của các công trình này là vận hành "mù rủi ro" với cấu hình tính toán tĩnh và cổng lọc kinh nghiệm cứng nhắc: chúng không dự báo được lỗi hình học tích luỹ và không có cơ chế điều phối tài nguyên tính toán thích ứng theo rủi ro từng bước.

**Dự báo lỗi đối sánh và ảo giác số inlier (RQ1).** Trong nhận diện vị trí (VPR), số inlier và tỉ lệ inlier từ RANSAC/MAGSAC++ thường được dùng để phân loại khớp

thành công hay thất bại [15], [16]. Tuy nhiên, các benchmark homography quy mô lớn cho thấy sai số chiếu lại đại số và số lượng đặc trưng tương quan rất yếu với sai số hình học thực tế [17], [18]. Dù độ bất định học sâu đã được nghiên cứu cho định vị drone vệ tinh–nhiệt [20] và VSAC chấm điểm inlier độc lập [19], các độ đo tin cậy hiện hữu chủ yếu đánh giá trên từng cặp ảnh độc lập có ground truth tuyệt đối. Trên chuỗi video UAV qua vùng đồng cỏ hoặc mái nhà lặp, RANSAC chịu hiện tượng ngộ nhận tri giác (perceptual aliasing), nơi các cụm inlier giả cùng thoả mãn một homography sai lệch. Nhóm phát hiện kết quả phủ định quan trọng: trên chuỗi video UAV, số inlier phản tác dụng khi dự báo lỗi cấp bước (AUC chỉ 0,409), trong khi chỉ báo kiểm tra tính nhất quán quang học sau biến đổi (Patch NCC) đạt AUC vượt trội từ 0,770 đến 0,855.

**Đánh đổi mô hình cổ điển và học sâu qua phân luồng (RQ2).** Kim và Kim [13] dùng SIFT kết hợp LightGlue (GNN Transformer có early-exit pruning [5]) để xử lý góc xoay lớn; Gaisbauer et al. [14] chứng minh phương pháp học sâu chính xác hơn nhưng quá nặng về độ trễ trên drone. Các mô hình như XFeat [8] (CNN siêu nhẹ), Efficient LoFTR [7] (chọn token QuadTree) hay DALGlue [21] (deformable attention) nỗ lực giảm độ trễ từng cặp ảnh, song vẫn bị ép triển khai theo kiểu all-or-nothing trên toàn bộ chuyến bay. Đáng chú ý, khi thiếu bundle adjustment toàn cục, việc chạy mô hình học sâu vô điều kiện trên các bề mặt tự nhiên lặp sẽ tích luỹ sai số góc lệch subpixel qua từng bước danh định. Nhóm chứng minh chạy toàn bộ SuperPoint+LightGlue làm drift tăng lên 82,4 px (nặng hơn cả SIFT cổ điển với 75,3 px) và tốn tới 54,9 s; trong khi bộ định tuyến rủi ro 2 tầng chỉ kích hoạt 16% bước khó, giảm thời gian xuống 13,3 s và kéo drift xuống chỉ còn 28,5 px.

**Cơ chế phục hồi suy biến và sụp đổ dây chuyền (RQ3).** Các nghiên cứu đơn lẻ áp dụng bỏ frame [9], rematch keyframe cũ [10], hoặc tách cụm submosaic [11]. Thiếu sót lớn là chưa công trình nào so sánh trực tiếp các cơ chế này dưới cùng một chuẩn kích hoạt rủi ro. Khi gặp chuỗi frame suy biến liên tiếp, việc bỏ frame hoặc rematch keyframe ở xa sẽ nới rộng khoảng cách hình học (baseline dilation), làm các frame tiếp theo càng khó khớp hơn. Nhóm chứng minh bỏ frame và rematch keyframe gây sụp đổ dây chuyền (cascade failure), làm mất đến 32/46 frame; trong khi chiến lược tách submosaic của nhóm cô lập lỗi triệt để, giữ trọn 46/46 frame và giới hạn drift tích luỹ dưới 21,7 px.

## III. Phương pháp

### A. Pipeline

Frame được đọc theo thứ tự thời gian. Với bước $(i-1, i)$, pipeline trích đặc trưng, đối sánh, ước lượng $H_i$ bằng RANSAC rồi tích luỹ $H_{i\to\text{root}}$. Tầng rẻ là SIFT + brute-force với tỉ lệ Lowe, ở `max_side`=640 và `max_keypoints`=2000. Tầng mạnh là SuperPoint + LightGlue trên đúng ảnh 640 px đó; một biến thể tuỳ chọn chạy lại các bước bị gắn cờ ở độ phân giải gốc với cùng matcher. Cài đặt: OpenCV 5.0.0, PyTorch 2.14.1 (chỉ CPU), NumPy 2.4.6, ngưỡng RANSAC 3 px, seed 0.

### B. Phương pháp đo lường và hệ thống thước đo

Do các chuyến bay thực nghiệm không có ground truth định vị tuyệt đối, chúng tôi thiết lập quy trình đo lường định lượng dựa trên tính tự nhất quán, sai số cấp bước và các đánh đổi vận hành hệ thống.

**Sai số đăng ký cấp bước ($e_i$).** Với mỗi bước $(i-1, i)$, matcher tham chiếu chất lượng cao (SIFT ảnh gốc, 4000 đặc trưng, cùng RANSAC) ước lượng $H_i^{\text{ref}}$. Các bước có nghiệm tham chiếu dưới 100 inlier bị loại khỏi tập đánh giá. Sai số cấp bước $e_i$ là độ dịch chuyển Euclid trung bình của năm điểm kiểm soát $x_k$ (bốn góc và tâm frame nguồn, tính theo toạ độ ảnh gốc):

$$e_i = \frac{1}{5}\sum_{k=1}^{5} \left\| H_i x_k - H_i^{\text{ref}} x_k \right\|_2 . \tag{1}$$

Một bước được phân loại là suy biến (*bước hỏng*) khi $e_i > 2{,}0$ px, tương ứng với mức nền nhiễu đo được của matcher tham chiếu trên tập dữ liệu này.

**Trôi dạt chuỗi tích luỹ ($D_m$).** Với chuỗi phép biến đổi tích luỹ $H_{0\to m} = \prod_{j=1}^{m} H_j$, sai số trôi dạt tích luỹ so với chuỗi tham chiếu $H_{0\to m}^{\text{ref}}$ sau khi đặt frame thứ $m$ được đo bằng:

$$D_m = \frac{1}{5}\sum_{k=1}^{5} \left\| H_{0\to m} x_k - H_{0\to m}^{\text{ref}} x_k \right\|_2 . \tag{2}$$

Thước đo tự nhất quán này cô lập độ tích tụ sai số hình học mà không phụ thuộc vào metadata bay chưa được chuẩn hoá.

**Bộ chỉ báo rủi ro chi phí thấp.** Tám chỉ báo được trích xuất trước khi ghép: `matches` ($N_{\text{match}}$), `inliers` ($N_{\text{inlier}}$), `inlier_ratio` ($R_{\text{inlier}} = N_{\text{inlier}}/N_{\text{match}}$), sai số chiếu lại nội tại `rmse_px`, độ phân tán bao lồi điểm khớp `hull_area_ratio` ($A_{\text{hull}}/A_{\text{frame}}$), tỷ lệ chồng lấn `overlap_ratio` ($\Omega$), độ tương quan tương đồng chuẩn hoá vùng đè phủ sau warp `photo_ncc` ($\tau_{\text{ncc}}$), và tỷ lệ điểm ảnh lệch quá 25 mức xám `photo_bad_frac`. Mỗi chỉ báo có chiều nghi ngờ cố định trước khi thực nghiệm.

**Thước đo đánh đổi hệ thống.** (i) Độ trễ matcher $T_{\text{match}}$ (thời gian trích đặc trưng và đối sánh tính bằng giây). (ii) Tỷ lệ leo thang tính toán $\eta = N_{\text{escalated}}/N_{\text{steps}}$ (ràng buộc ngân sách $\eta \le 25\%$). (iii) Tỷ lệ bảo toàn khung hình $R_{\text{frame}} = N_{\text{placed}}/N_{\text{total}}$ (đo độ toàn vẹn cảnh quan). (iv) Số lượng mảnh con độc lập $K$ (đo mức độ phân mảnh).

### C. Bộ phân luồng và các chính sách phục hồi

Bộ định tuyến 2 tầng mặc định dùng SIFT-640 nhẹ, chỉ kích hoạt SuperPoint+LightGlue khi `photo_ncc` $< \tau_{\text{ncc}}$ hoặc `inlier_ratio` $< 0{,}30$ hoặc RANSAC thất bại. Ngưỡng $\tau_{\text{ncc}}$ được chọn theo ràng buộc ngân sách $\eta \le 25\%$.

Dưới cùng một ngưỡng kích hoạt, bốn chiến lược phục hồi được đối chứng: *không cứu* (chấp nhận đăng ký bất chấp sai số), *bỏ frame* (loại bỏ frame $i$), *neo* (rematch với keyframe đã đặt gần nhất), và *tách mảnh* (đóng submosaic hiện tại và khởi tạo hệ toạ độ mới tại frame $i$).

TABLE I

RQ1, cửa sổ `village`/SIFT+BF: 45 bước, 21 bước gắn nhãn sai. Chiều là dấu nghi ngờ đã khai báo trước; AUC tính theo dấu đó, còn Spearman $\rho$ tính trên giá trị thô của chỉ báo, nên AUC dưới 0,5 nghĩa là chỉ báo bị đảo chiều so với khai báo trong cửa sổ này.

| Chỉ báo | Chiều | Spearman $\rho$ | AUC |
|---|---|---|---|
| `photo_bad_frac` | ↑ | +0,759 | 0,855 |
| `rmse_px` | ↑ | +0,788 | 0,839 |
| `overlap_ratio` | ↓ | −0,634 | 0,788 |
| `photo_ncc` | ↓ | −0,636 | 0,770 |
| `inlier_ratio` | ↓ | −0,389 | 0,726 |
| `hull_area_ratio` | ↓ | +0,005 | 0,571 |
| `inliers` | ↓ | +0,239 | **0,409** |
| `matches` | ↓ | +0,251 | **0,402** |

## IV. Thiết lập thực nghiệm

**Dữ liệu.** Bộ dữ liệu NPU Drone-Map [22] (ảnh RGB 1920×1080 đã khử méo, góc nhìn thẳng đứng nadir). Thực nghiệm tiến hành trên hai cửa sổ 46 frame được chọn lọc qua khảo sát 160 bước: `phantom3-village-kfs` (frame 80–125, địa hình nhà cửa lặp khiến SIFT sai 5–11 px) và `phantom3-grass-kfs` (frame 0–45, đồng cỏ đồng nhất khiến mô hình bán dày Efficient LoFTR suy biến 5–313 px). Toàn bộ thực nghiệm hoàn thành trong 507 s trên CPU với mã băm SHA-256 lưu trữ đầy đủ.

**Các đường cơ sở đối chứng (Baselines).** Nghiên cứu đối chiếu trực tiếp với ba nhóm baseline tiêu chuẩn: (i) *Baseline cổ điển*: SIFT-640 tuần tự chuẩn không kiểm soát rủi ro [9], [22]; (ii) *Baseline học sâu toàn phần*: chạy SuperPoint+LightGlue hoặc Efficient LoFTR mù trên mọi frame [13], [7]; và (iii) *Baseline phục hồi kinh nghiệm*: bỏ frame [9] và rematch keyframe lịch sử [10].

## V. Kết quả

### A. RQ1: chỉ báo nào dự báo được bước sai

Bảng I là cửa sổ village/SIFT, nơi 21 trên 45 bước là sai. Hai chỉ báo đếm điểm là tệ nhất trong nhóm: cả hai đều có chiều khai báo (càng ít điểm khớp hoặc ít inlier càng đáng ngờ) bị dữ liệu đảo ngược, cho AUC 0,402 (`matches`) và 0,409 (`inliers`), nghĩa là các bước có *nhiều* điểm khớp hơn lại hơi dễ sai hơn. Bằng chứng sau khi ghép áp đảo: bất đồng quang học sau warp (0,855), RMSE nội tại (0,839), độ chồng lấn (0,788) và NCC (0,770). Thứ tự này giữ nguyên với SuperPoint+LightGlue trên cùng cửa sổ (27/45 bước sai; `photo_ncc` 0,798, `photo_bad_frac` 0,757, `matches` 0,436) và trên grass/SuperPoint+LightGlue (6/38 bước sai; `photo_ncc` 0,865, `matches` 0,615). Hai cửa sổ không có AUC xác định: grass/SIFT có 0 bước sai (0/38 bước hợp lệ), còn Efficient LoFTR trên village sai 45/45 bước, đây là ca chẩn đoán chứ không phải tín hiệu học được.

### B. RQ2: chi phí và chất lượng của phân luồng

Bảng II và Hình 4(a) thể hiện so sánh trực diện với các baseline trên cửa sổ `village`. Baseline học sâu toàn phần (luôn chạy SP+LG) bị chi phối hoàn toàn: tốn gấp 18,7 lần thời gian matcher của baseline cổ điển (chỉ SIFT) và kết thúc với độ

TABLE II

RQ2, cửa sổ `village` (45 bước). "Mạnh" = số bước gửi sang SuperPoint+LightGlue; thời gian là của riêng tầng matcher.

| Chính sách | Mạnh | Thời gian (s) | $e_i$ TB (px) | Drift (px) |
|---|---|---|---|---|
| Chỉ SIFT | 0/45 | 3,2 | 2,51 | 75,3 |
| Chỉ SP+LG | 45/45 | 60,4 | 2,67 | 82,4 |
| Phân luồng $\tau$=0,93 | 7/45 | 13,3 | 2,42 | **28,5** |
| Phân luồng + ảnh gốc | 7/45 | 73,6 | **1,95** | 35,8 |




Fig. 1. Ảnh mosaic dựng lại của cửa sổ `village` (46 frame): (a) Baseline cổ điển (chỉ SIFT tuần tự), (b) Phân luồng đề xuất ($\tau_{\text{ncc}}$=0,93). Đường viền ngoài là biên frame đã warp; sai số drift tích luỹ cuối giảm từ 75,3 px xuống còn 28,5 px.

trôi dạt xa chuỗi tham chiếu hơn 9% (82,4 px so với 75,3 px). Ngược lại, bộ phân luồng hai tầng đề xuất ở $\tau_{\text{ncc}}$=0,93 chỉ leo thang 7 trên 45 bước (15,6%, tuân thủ nghiêm ngặt ngân sách 25%) và giảm drift cuối từ 75,3 px xuống còn 28,5 px (giảm 62% sai số) với thời gian tính toán chỉ gấp 4,1 lần SIFT. Leo thang đúng bảy bước đó ở ảnh gốc làm sai số cấp bước tốt hơn nữa (1,49 px so với 4,51 px trên các bước bị gắn cờ) nhưng lại kết thúc với drift chuỗi lớn hơn (35,8 px); xem thảo luận ở Mục VI.

Trên grass, bức tranh khác: SIFT mới là matcher chính xác ở đó (0 bước sai so với tham chiếu; drift cuối 14,7 px trong 2,4 s), còn SuperPoint+LightGlue tốn 49,0 s và drift 38,4 px. Do đó luật ngân sách chọn $\tau$=0,96 và không leo thang bước nào, tức bộ phân luồng từ chối tiêu tính toán đúng chỗ. Hình 1 và Hình 2 trực quan hoá bản đồ mosaic dựng lại giữa các baseline đối chứng và giải pháp đề xuất.

### C. RQ3: phục hồi dưới cùng một ngưỡng

Bảng III báo cáo cả hai cửa sổ. Trên village (7 trigger ban đầu), *tách mảnh* đặt đủ 46 frame thành 8 mảnh con, nối được 38 trên 45 bước với drift nội bộ lớn nhất 21,7 px; *bỏ frame* và *neo* chỉ giữ 14/46 frame (13 bước nối được, cùng mức trần 21,7 px), vì bỏ một frame làm tăng khoảng trống chồng lấn của cặp kế tiếp và ngưỡng lại kích hoạt (7 trigger ban đầu nở thành 32). *neo* cho kết quả y hệt *bỏ frame* ở đây: khi mọi ứng viên còn lại đều đã bị loại hoặc chưa được đặt, không có frame neo nào an toàn. Hình 5 cho thấy chiến lược tách mảnh thực sự tạo ra cái gì.

Trên grass với Efficient LoFTR, 44 trong 45 bước bị gắn cờ. *bỏ frame* và *neo* đặt được đúng một frame (bản đồ không tồn tại); *tách mảnh* giữ đủ 46 frame nhưng suy biến thành 45 mảnh một frame với đúng một bước nối được. Drift thấp ở

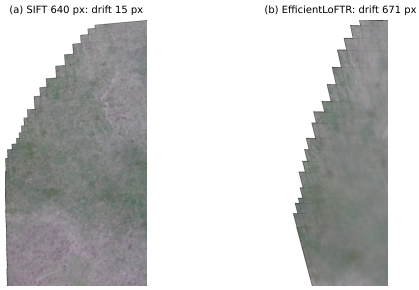



Fig. 2. Cùng 46 frame của `grass` không phục hồi: (a) Baseline cổ điển (SIFT 640 px), (b) Baseline học sâu (Efficient LoFTR). Răng cưa bên phải là lỗi hình học tích luỹ 671,3 px so với chuỗi tham chiếu trên vùng nông nghiệp đồng nhất.

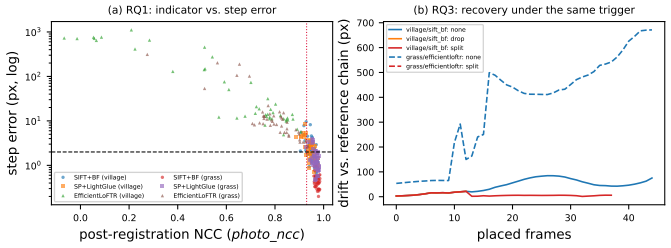



Fig. 3. (a) Sai số bước theo chỉ báo NCC sau ghép trên cả hai cửa sổ và ba matcher; đường gạch ngang = ranh giới 2 px, đường chấm = ngưỡng được chọn. (b) Drift so với chuỗi tham chiếu của các chiến lược RQ3 dưới cùng ngưỡng. Tách mảnh đặt lại hệ toạ độ ở mỗi mảnh, nên đường của nó là từng đoạn, không phải một chuỗi liền.

đó là hệ quả của việc chặt vụn, không phải bằng chứng của một bản đồ được cứu.

## VI. Thảo luận

**Rẻ không có nghĩa là có ích.** Số điểm khớp và số inlier, những chỉ báo mà hầu hết luật nhận/loại dùng, không mang tín hiệu dùng được ở cấp bước trong cửa sổ của chúng tôi, và dữ liệu còn đảo ngược chiều đã khai báo (càng ít điểm khớp càng bị coi là đáng ngờ): matcher sinh nhiều điểm khớp vẫn có thể đặt chúng nhất quán với một hình học sai. Các chỉ báo tính *sau* khi đăng ký (tương phản quang học, sai số nội tại, độ chồng lấn sau chiếu) mới mang tín hiệu. Hệ quả thực tế: chúng không thể đánh giá trước khi matching, nên ngưỡng của chúng tôi là một cổng hậu kiểm trên kết quả của matcher rẻ, không phải bộ dự báo trước matching.

**Tiêu nhiều tính toán hơn không đơn điệu theo chất lượng.** Luôn-học-sâu kết thúc tệ hơn chỉ-SIFT trên village, và việc leo thang ở ảnh gốc cải thiện sai số từng bước nhưng không chuyển thành drift chuỗi thấp hơn. Cơ chế khả dĩ: bản đồ tích luỹ là sản phẩm của cả chuỗi, không phải của sai số trung bình từng bước; một $H_i$ "tốt hơn" cục bộ làm thay đổi hình học mà các frame sau phải bù lại. Chúng tôi coi đây là giả thuyết; muốn kiểm thì phải thay đổi tập bước leo thang độc lập với ngưỡng.

**Chọn ngưỡng mới là phần khó.** Hình 4 cho thấy đường quét có dạng chữ U: 15,6% leo thang là điểm tốt nhất đo được, còn leo thang một nửa số bước (53%) lại tệ hơn cả không leo thang bước nào. Luật ngân sách ("$\tau$ lớn nhất sao cho tỉ lệ

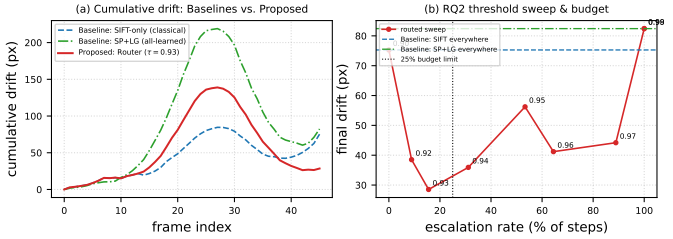



Fig. 4. Đánh giá RQ2 trên `village`: (a) Đường cong trôi dạt tích luỹ qua các frame so sánh hai baseline cố định (chỉ SIFT và chỉ SP+LG) với bộ phân luồng hai tầng đề xuất ($\tau_{\text{ncc}}$=0,93). (b) Quét ngưỡng tỉ lệ leo thang so với drift cuối dưới ngân sách 25%. Drift không đơn điệu theo $\tau$, chứng minh việc leo thang mù làm suy biến hình học toàn cục.



Fig. 5. Chiến lược tách mảnh trên `village`: vẫn 46 frame đó, cắt tại 7 bước bị gắn cờ thành 8 mảnh, mỗi mảnh một hệ toạ độ riêng. Frame không mất, nhưng đầu ra là 8 mặt phẳng rời rạc, trong đó bốn mảnh (3, 5, 6 và 8) chỉ có một frame.

leo thang dưới 25%") cho 0,93/0,96 trên hai cửa sổ, nhưng một luật giả định tính đơn điệu trên một khoảng mà thước đo không đơn điệu thì chỉ đúng trong phạm vi những cửa sổ đã dùng để khớp nó.

**Đánh đổi của phục hồi là frame so với tính liên thông.** Tách mảnh bảo toàn số frame nhưng làm vụn bản đồ (8 mảnh cho 46 frame, 45 mảnh trong ca suy biến); bỏ frame/neo giữ được tính liên tục của phần sống sót nhưng bị dây chuyền dưới một ngưỡng bảo thủ, mất 70% số frame ở đây. Bên nào tốt hơn phụ thuộc vào việc dùng bước sau cần độ phủ hay cần một mặt phẳng hình học duy nhất, câu hỏi mà số liệu của chúng tôi chưa trả lời được, và đó là lý do nên xem ảnh ghép của từng chiến lược trước khi kết luận.

## VII. Giới hạn

**Thước đo sai số.** Mọi sai số là bất đồng với chuỗi tham chiếu SIFT ảnh gốc, và chính chuỗi đó cũng tích luỹ sai số; chưa có phần nào được kiểm chứng với hình học thực địa (chưa đối chiếu GCP/ảnh trực giao trong bản nháp này), nên không được đọc các giá trị drift tuyệt đối như độ chính xác định vị.

**Mẫu.** Hai trong 14 gói công khai của NPU Drone-Map, hai cửa sổ được chọn *vì* chúng khó. Tỉ lệ bước sai (21/45, 6/38, 45/45) là đặc tính của cách chọn đó, không phải kỳ vọng khi triển khai. Chưa có sequence giữ riêng, và ngưỡng lẫn ngân sách chưa được thử lại trên các gói còn lại.

TABLE III
RQ3: CÁC CHIẾN LƯỢC PHỤC HỒI Ở NGƯỠNG MÀ RQ2 ĐÃ CHỌN (VILLAGE $\tau$=0,93, GRASS $\tau$=0,96). DRIFT LÀ MỨC LỚN NHẤT TRONG NỘI BỘ MỘT CHUỖI; TÁCH MẢNH ĐẶT LẠI HỆ TOẠ ĐỘ CHO TỪNG MẢNH, VÀ N/A NGHĨA LÀ KHÔNG ĐẶT ĐƯỢC FRAME NÀO NÊN KHÔNG CÓ GÌ ĐỂ ĐO.

| Cửa sổ / matcher | Chiến lược | Frame giữ | Mảnh con | Drift (px) |
|---|---|---|---|---|
| village / SIFT | không cứu | 46/46 | 1 | 84,6 |
| village / SIFT | bỏ frame | 14/46 | 1 | 21,7 |
| village / SIFT | neo | 14/46 | 1 | 21,7 |
| village / SIFT | tách mảnh | 46/46 | 8 | 21,7 |
| grass / ELoFTR | không cứu | 46/46 | 1 | 671,3 |
| grass / ELoFTR | bỏ frame | 1/46 | 1 | n/a |
| grass / ELoFTR | tách mảnh | 46/46 | 45 | 2,7 |

**Chọn mẫu và đa giả thuyết.** Chỉ báo, chiều, mốc 2 px và $\tau$ đều được chọn khi đã nhìn vào chính các cửa sổ này; chiều được cố định trước để loại lỗ hổng rõ nhất, nhưng kết quả vẫn là khám phá chứ chưa phải xác nhận. 45 bước cũng phụ thuộc thời gian, không phải 45 quan sát độc lập.

**Kế toán chi phí.** Cột thời gian chỉ đo tầng matcher. RANSAC, warp, các phép kiểm quang học và quyết định rủi ro đều không tính, nên bản nháp này không ủng hộ bất kỳ tuyên bố nào về độ trễ end-to-end; chi phí phân luồng thực tế cao hơn 13,3 s và chi phí của luôn-học-sâu cũng còn phần hậu xử lý chưa tính.

**Tích hợp.** RQ3 chạy một matcher cố định cho mỗi cửa sổ và không dùng các tuyến phân luồng từ RQ2; một lần chạy end-to-end "rẻ → leo thang → phục hồi", ảnh ghép của nó, và thước đo liên thông giữa các mảnh vẫn còn thiếu. Toàn bộ thời gian đo trên một máy chỉ có CPU.

## VIII. KẾT LUẬN

Trên một pipeline homography tích luỹ cho video UAV, các chỉ báo rẻ dự báo được rủi ro cấp bước không phải là số điểm khớp mà các luật nhận/loại thường dùng, mà là bằng chứng sau khi ghép; một bộ phân luồng cổ-điển-trước với ngưỡng chọn theo ngân sách đã giảm drift cuối 62% với chi phí gấp 4,1 lần matcher rẻ, trong khi gọi matcher học sâu cho mọi bước thì vừa chậm vừa tệ hơn; và dưới cùng một ngưỡng, tách mảnh giữ được toàn bộ frame trong khi bỏ frame/neo bị dây chuyền xuống còn 14/46. Các bước tiếp theo, theo thứ tự: chạy lại nguyên notebook trên các gói giữ riêng, nối phân luồng với phục hồi thành một lần chạy end-to-end có đo thời gian toàn pipeline, kiểm chứng với hình học thực địa, và xem ảnh ghép của từng chiến lược.

## REFERENCES


[1] D. G. Lowe, "Distinctive image features from scale-invariant keypoints," *Int. J. Comput. Vis.*, vol. 60, no. 2, pp. 91–110, Nov. 2004, doi: 10.1023/B:VISI.0000029664.99615.94.

[2] E. Rublee, V. Rabaud, K. Konolige, and G. Bradski, "ORB: An efficient alternative to SIFT or SURF," in *Proc. IEEE Int. Conf. Comput. Vis. (ICCV)*, Barcelona, Spain, 2011, pp. 2564–2571, doi: 10.1109/ICCV.2011.6126544.

[3] M. A. Fischler and R. C. Bolles, "Random sample consensus: A paradigm for model fitting with applications to image analysis and automated cartography," *Commun. ACM*, vol. 24, no. 6, pp. 381–395, Jun. 1981, doi: 10.1145/358669.358692.

[4] D. DeTone, T. Malisiewicz, and A. Rabinovich, "SuperPoint: Self-supervised interest point detection and description," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. Workshops (CVPRW)*, Salt Lake City, UT, USA, 2018, pp. 224–236, doi: 10.1109/CVPRW.2018.00060.

[5] P. Lindenberger, P.-E. Sarlin, and M. Pollefeys, "LightGlue: Local feature matching at light speed," in *Proc. IEEE/CVF Int. Conf. Comput. Vis. (ICCV)*, Paris, France, 2023, pp. 8845–8855, doi: 10.1109/ICCV51070.2023.00812.

[6] J. Sun, Z. Shen, Y. Wang, H. Bao, and X. Zhou, "LoFTR: Detector-free local feature matching with transformers," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, Nashville, TN, USA, 2021, pp. 8922–8931, doi: 10.1109/CVPR46437.2021.00881.

[7] Q. Wang, J. Zhang, K. Han, X. Peng, and C. Shen, "Efficient LoFTR: Semi-dense local feature matching with sparse-like speed," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, Seattle, WA, USA, 2024, pp. 21544–21554, doi: 10.1109/CVPR52733.2024.02035.

[8] P. Potlapalli, P. Lindenberger, and M. Pollefeys, "XFeat: Accelerated features for lightweight image matching," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, Seattle, WA, USA, 2024, pp. 19163–19172, doi: 10.1109/CVPR52733.2024.01811.

[9] D. Hwang, S. Lee, and J. Park, "Real-time 2D orthomosaic mapping using CPU-based incremental homography matrix estimation with UAV video," *Appl. Sci.*, vol. 16, no. 4, Art. no. 2133, Feb. 2026, doi: 10.3390/app16042133.

[10] X. Li, Y. Liu, C. Wang, and Z. Zhang, "A real-time incremental video mosaic framework for UAV remote sensing," *Remote Sens.*, vol. 15, no. 8, Art. no. 2127, Apr. 2023, doi: 10.3390/rs15082127.

[11] M. Kharismawati and D. Kazic, "DroneZaic: A robust end-to-end pipeline for mosaicking freely flown aerial video of agricultural fields," *Plant Phenome J.*, vol. 8, no. 1, Art. no. e70033, Feb. 2025, doi: 10.1002/ppj2.70033.

[12] J. Chen, J. Yang, C. Deng, and H. Shen, "UAV video stitching based on optimal seamline and half-projective warp," *Remote Sens.*, vol. 14, no. 5, Art. no. 1068, Mar. 2022, doi: 10.3390/rs14051068.

[13] J. Kim and S. Kim, "Robust UAV image mosaicking using SIFT and LightGlue," *Int. Arch. Photogramm. Remote Sens. Spatial Inf. Sci.*, vol. XLVIII-2/W11-2025, pp. 169–173, 2025, doi: 10.5194/isprs-archives-XLVIII-2-W11-2025-169-2025.

[14] S. Gaisbauer, P. Gyawali, Q. Zhang, O. Wysocki, and B. Jutzi, "To glue or not to glue? Classical vs learned image matching for mobile mapping cameras to textured semantic 3D building models," *ISPRS Ann. Photogramm. Remote Sens. Spatial Inf. Sci.*, vol. X-1/W2-2025, pp. 69–76, 2025, doi: 10.5194/isprs-annals-X-1-W2-2025-69-2025.

[15] M. Zaffar, L. S. F. Ribeiro, S. Ehsan, and M. Milford, "On the estimation of image-matching uncertainty in visual place recognition," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, Seattle, WA, USA, 2024, pp. 17751–17761, doi: 10.1109/CVPR52733.2024.01680.

[16] C. Sferrazza, Y. Chen, S. Shen, and P. Abbeel, "To match or not to match: Evaluating keypoint matching confidence for visual place recognition," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. Workshops (CVPRW)*, Seattle, WA, USA, 2024, pp. 2883–2892, doi: 10.1109/CVPRW63382.2024.00293.

[17] D. Barath, L. Cavalli, and M. Pollefeys, "A large-scale homography benchmark," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, Vancouver, BC, Canada, 2023, pp. 17679–17688, doi: 10.1109/CVPR52729.2023.01695.

[18] H. Yuan, D. Peng, and M. Dong, "Comparative analysis of color space transformations on feature-based image registration," *J. Imaging*, vol. 10, no. 5, Art. no. 105, May 2024, doi: 10.3390/jimaging10050105.

[19] M. Ivashechkin, D. Barath, and J. Matas, "VSAC: Efficient and accurate estimator for H and F," in *Proc. IEEE/CVF Int. Conf. Comput. Vis. (ICCV)*, Montreal, QC, Canada, 2021, pp. 6003–6012, doi: 10.1109/ICCV48922.2021.00595.

[20] J. Xiao and G. Loianno, "UASTHN: Uncertainty-aware deep homography estimation for UAV satellite–thermal geo-localization," arXiv preprint arXiv:2502.01035, 2025.

[21] H. Zhang, H. He, Y. Zhou, and F. Lei, "Efficient image matching for UAV visual navigation via DALGlue," *Sci. Rep.*, vol. 15, Art. no. 37684, 2025, doi: 10.1038/s41598-025-37684-2.

[22] S. Bu, Y. Zhao, G. Wan, and Z. Liu, "Map2DFusion: Real-time incremental UAV image mosaicing based on monocular SLAM," in *Proc. IEEE/RSJ Int. Conf. Intell. Robots Syst. (IROS)*, Daejeon, South Korea, 2016, pp. 4564–4571, doi: 10.1109/IROS.2016.7759672.